

Parametrizácia genetického algoritmu

Genetic Algorithm Parameterization

Obsah

Úloha 1: Parametrizácia genetického algoritmu	2
Cieľ úlohy	2
Definícia úlohy	2
Experiment 1: Selektívny tlak a diverzita	2
Experiment 2: Vplyv genetických operátorov	3
Postup riešenia	3
Požadované výstupy	3
Bonusová úloha (+1 bod)	4
Odovzdanie a hodnotenie	5
Dokumentácia výsledkov (PDF)	5
Obhajoba riešenia	5
Odporúčané nástroje a technická realizácia	6
Python – primárne prostredie	6
MATLAB – alternatíva	6
Teoretické poznámky	7
Selektívny tlak a diverzita populácie	7
Globálna a lokálna mutácia	7
Ablačný experiment	7
Interpretácia stochastických výsledkov	7

Úloha 1: Parametrizácia genetického algoritmu (4 b + 1 b bonus)

V tomto zadaní budete systematicky meniť parametre genetického algoritmu a porovnávať správanie jednotlivých variantov. Výsledkom nebude iba funkčná implementácia, ale aj experimentálne zdôvodnenie toho, ktoré nastavenia a operátory pomáhajú pri riešení danej optimalizačnej úlohy.

Cieľ úlohy

Cieľom zadania je experimentálne preskúmať vplyv nastavenia genetického algoritmu na jeho konvergenciu. Zamerajte sa na vzťah medzi **selektívnym tlakom** a **diverzitou populácie** a následne vyhodnoťte prínos kríženia, globálnej mutácie a lokálnej mutácie.

Na základe opakovaných behov navrhnete vhodný kompromis medzi rýchlosťou konvergenzie, kvalitou nájdeného riešenia a schopnosťou algoritmu prehľadávať rôzne oblasti priestoru riešení.

Definícia úlohy

Genetický algoritmus aplikujte na minimalizáciu **Schwefelovej funkcie desiatich premenných** implementovanej vo funkcii `testfn3`:

$$f(\mathbf{x}) = \sum_{j=1}^{10} -x_j \sin\left(\sqrt{|x_j|}\right), \quad \mathbf{x} = [x_1, x_2, \dots, x_{10}].$$

Vo všetkých povinných experimentoch použite populáciu s veľkosťou **50 jedincov**. Ostatné nastavenia, ktoré nie sú predmetom konkrétneho porovnania, udržiavajte medzi variantmi rovnaké. Patria sem najmä hranice premenných, spôsob inicializácie, maximálny počet generácií, ukončovacie podmienky a spôsob zaznamenávania fitness.

Každý variant spustíte viackrát ako samostatné nezávislé behy. Počet behov nie je pevne určený, musí však byť dostatočný na zmysluplné porovnanie jednotlivých priebehov a ich priemeru. Ak používate generátor náhodných čísel, zaznamenajte použité seedy alebo použite rovnakú sadu seedov pre všetky porovnávané varianty.

Experiment 1: Selektívny tlak a diverzita

Vytvorte a porovnajte nasledujúcich päť variantov genetického algoritmu:

Variant	Selektívny tlak	Diverzita	Úloha
a	veľký	veľká	Zvoľte operátory a ich parametre tak, aby boli obe vlastnosti výrazné.
b	veľký	malá	Zvýhodnite najlepších jedincov a obmedzte vznik alebo zachovanie rozdielných riešení.
c	malý	veľká	Zachovajte širšie prehľadávanie priestoru pri miernejšom zvýhodňovaní najlepších jedincov.
d	malý	malá	Nastavte slabší selektívny tlak aj obmedzenú diverzitu populácie.
e	kompromis	kompromis	Na základe výsledkov a–d navrhnete a zdôvodnite prakticky vhodné nastavenie.

Tabuľka 1: Požadované varianty experimentu so selektívnym tlakom a diverzitou.

Pojmy *veľký* a *malý* nepredstavujú jednu predpísanú číselnú hodnotu. Musíte ich realizovať vhodným výberom selekcie, kríženia, mutácií a ich parametrov a svoje rozhodnutie vysvetliť v dokumentácii aj pri obhajobe.

Pre varianty a–e vytvorte prvú samostatnú skupinu grafov. V jednom prehľadnom obrázku zobrazte priebehy jednotlivých behov farebne a pre každý variant aj priemerný priebeh. Z grafu musí byť jednoznačné, ktorý priebeh patrí ku ktorému variantu.

Experiment 2: Vplyv genetických operátorov

Ako referenčné nastavenie použite kompromisný variant e. V každom ďalšom variante zmeňte iba uvedenú časť algoritmu; ostatné parametre ponechajte zhodné s variantom e.

Variant	Úprava voči variantu e	Operátory, ktoré zostávajú aktívne
f	eliminujte iba kríženie	globálna mutácia <code>mutx</code> a lokálna mutácia <code>muta</code>
g	eliminujte iba globálnu mutáciu <code>mutx</code>	kríženie a lokálna mutácia <code>muta</code>
h	eliminujte iba lokálnu mutáciu <code>muta</code>	kríženie a globálna mutácia <code>mutx</code>
i	eliminujte obe mutácie	kríženie; globálna ani lokálna mutácia sa nepoužije

Tabuľka 2: Ablačné experimenty s genetickými operátormi.

Varianty e–i opäť viackrát spustite a zdokumentujte v druhej samostatnej skupine grafov. Rovnako ako v prvom experimente zobrazte jednotlivé priebehy aj ich priemer.

Postup riešenia

1. Pripravte základný genetický algoritmus pre 10-D funkciu `testfn3` a overte, že správne vytvára populáciu 50 jedincov, vyhodnocuje fitness a iteruje cez generácie.
2. Zvoľte spoločné referenčné nastavenia experimentu. V dokumentácii uveďte najmä počet generácií, hranice premenných, spôsob inicializácie, selekčný operátor, operátor kríženia, globálnu a lokálnu mutáciu a všetky ich dôležité parametre.
3. Realizujte varianty a–d z Tab. 1. Pri každom variante uveďte, ktorými operátormi a parametrami ste dosiahli požadovaný selektívny tlak a diverzitu.
4. Na základe výsledkov a–d navrhnete variant e. Výber zdôvodnite pozorovanou rýchlosťou konvergenzie, stabilitou medzi behmi a kvalitou riešení.
5. Z variantu e vytvorte varianty f–i podľa Tab. 2. Pri každom variante odstráňte iba požadovaný operátor alebo skupinu operátorov.
6. Pre všetky varianty archivujte nastavenia, priebehy fitness a výsledné najlepšie riešenie. Výsledky spracujte do dvoch skupín grafov a do prehľadných tabuliek.
7. Diskutujte pozorované rozdiely. Osobitne vysvetlite predčasnú konvergenciu, stagnáciu, rozptyl medzi behmi a zmeny po vypnutí jednotlivých genetických operátorov.

Požadované výstupy

Dokumentácia musí obsahovať minimálne:

1. tabuľku spoločných nastavení experimentu a tabuľku parametrov variantov a–i,
2. prvú skupinu grafov pre varianty a–e, v ktorej sú jednotlivé behy a priemerné priebehy,
3. druhú skupinu grafov pre varianty e–i v rovnakom formáte,
4. tabuľku výsledkov jednotlivých behov a súhrnné porovnanie variantov,
5. najlepšie nájdené riešenie a jeho fitness pre zvolené kompromisné nastavenie,
6. stručnú diskusiu experimentov a zdôvodnenie výberu variantu e.

Všetky grafy musia mať rovnaký význam osí a porovnateľnú mierku. Os x označte ako generáciu alebo iteráciu a os y ako sledovanú hodnotu fitness. Ak namiesto najlepšej fitness v populácii zobrazujete inú štatistiku, jasne ju pomenujte a používajte ju konzistentne vo všetkých variantoch.

Bonusová úloha (+1 bod)

Zopakujte experimenty s **Eggholderovou funkciou desiatich premenných**. Použite rovnaký spôsob dokumentácie a porovnajte správanie genetického algoritmu so Schwefelovou funkciou. Vysvetlite rozdiely v konvergencii, stabilite behov a citlivosti na selektívny tlak, diverzitu a genetické operátory.

Odovzdanie a hodnotenie

Hodnotenie zadania prebieha formou osobnej konzultácie. Zadanie sa odovzdáva vždy na **začiatku cvičenia** po odprezentovaní nasledujúceho zadania.

Počas semestra môže študent nahradiť najviac dve cvičenia. V takom prípade je možné zadanie odovzdať aj na cvičení, na ktorom študent nahrádza. V ostatných prípadoch sa zadanie odovzdáva vždy svojmu cvičiacemu.

Povinná časť zadania je hodnotená najviac 4 bodmi. Bonusový bod je nad rámec základných 44 bodov za jedenásť povinných zadaní.

Dokumentácia výsledkov (PDF)

Pripravte stručnú správu vo formáte PDF, ktorá obsahuje požadované grafy a tabuľky z viacerých nezávislých spustení, použité nastavenia algoritmu a krátku analýzu výsledkov. Dokument musí byť pripravený pred začiatkom obhajoby, aby nebolo nutné čakať na opakované výpočty počas konzultácie.

Grafy exportujte priamo z použitého prostredia v dostatočnej kvalite, nie formou screenshotov. Každý graf musí obsahovať názov, popisy osí, čitateľnú mierku a legendu, ak zobrazuje viac priebehov. Výsledky spracujte do prehľadných tabuliek; samotný neupravený výpis z konzoly sa nepovažuje za dokumentáciu.

Pre toto zadanie musí správa obsahovať dve oddelené skupiny grafov (a–e a e–i), jednotlivé behy aj priemerné priebehy, tabuľky nastavení a výsledkov a diskusiu vplyvu selektívneho tlaku, diverzity, kríženia a oboch typov mutácie. Pri variante e uveďte výsledný najlepší vektor desiatich premenných a jeho fitness.

Obhajoba riešenia

Súčasťou hodnotenia je demonštrácia funkčného kódu a vysvetlenie implementácie. Body sa udeľujú najmä za porozumenie princípu algoritmu, použitým operátorom a schopnosť zdôvodniť zvolené parametre a dosiahnuté výsledky, nie iba za spustiteľný program.

Pri obhajobe buďte pripravení vysvetliť, ako sa v implementácii prejavuje selektívny tlak, diverzita populácie, kríženie a jednotlivé typy mutácie, a interpretovať rozdiely medzi opakovanými behmi.

Pri obhajobe vysvetlite, ktoré konkrétne operátory a parametre vytvárajú požadované kombinácie selektívneho tlaku a diverzity. Musíte vedieť ukázať, kde sa v hlavnom cykle vykonáva selekcia, kríženie, `mutx` a `muta`, a prečo sa výsledky jednotlivých behov môžu líšiť.

Odporúčané nástroje a technická realizácia

Primárnym prostredím pre zadania UI2 je jazyk **Python**. Odporúčané je prostredie **Google Colab** (<https://colab.research.google.com/>) alebo lokálny Jupyter Notebook. Ako alternatívu je možné použiť **MATLAB** s podkladmi dostupnými v AIS, ak zadanie neurčí inak.

Python – primárne prostredie

Pre Python používajte oficiálne podklady predmetu:

- **Kódy a podklady pre GA blok UI2:** <https://github.com/STU-FEI-OUI/UI2-GA>
- **Spoločný Genetic Toolbox:** <https://github.com/STU-FEI-OUI/Genetic-toolbox>

Testovacia funkcia `testfn3.py` sa nachádza v priečinku `kod` repozitára UI2-GA. Pri implementácii používajte operátory zo spoločného toolboxu, ale hlavný riadiaci cyklus genetického algoritmu a experimentálny kód spracujte prehľadne vo vlastnom programe.

Pri tomto zadaní použite funkciu `kod/testfn3.py` z repozitára UI2-GA. Operátory `mutx`, `muta` a vhodné selekčné a krížiace operátory sú dostupné v spoločnom Genetic Toolboxe. Odkazy na odporúčaný notebook a manuál sú uvedené v hlavnom súbore README repozitára UI2-GA.

MATLAB – alternatíva

Pri riešení v Matlabe použite program `GA01`, testovaciu funkciu `testfn3.m` a príslušnú verziu Genetic Toolboxu dostupnú v AIS. Zachovajte rovnakú experimentálnu metodiku a rovnaký rozsah dokumentácie ako pri riešení v Pythone.

Teoretické poznámky

Nasledujúce pojmy tvoria teoretický základ experimentov v tomto zadaní. Pri obhajobe ich musíte vedieť prepojiť s konkrétnymi operátormi, parametrami a pozorovanými priebehmi vášho algoritmu.

Selektívny tlak a diverzita populácie

Selektívny tlak vyjadruje, ako výrazne výber zvýhodňuje úspešnejších jedincov. Silný tlak môže urýchliť zlepšovanie fitness, ale zároveň rýchlo zjednotiť populáciu a spôsobiť predčasnú konvergenciu. Slabší tlak ponecháva väčšiu šancu aj horším jedincom, čím môže podporiť prieskum priestoru, ale zvyčajne spomaľuje konvergenciu.

Diverzita vyjadruje rôznorodosť genetickej informácie v populácii. Veľká diverzita pomáha objavovať nové oblasti priestoru riešení; príliš malá diverzita zvyšuje riziko stagnácie. Samotná vysoká diverzita však nezaručuje kvalitné riešenie, ak algoritmus nedokáže využiť už nájdené dobré oblasti.

Globálna a lokálna mutácia

Globálna mutácia `mutx` môže nahradiť hodnotu génu novou hodnotou z povoleného rozsahu, preto podporuje väčšie skoky v priestore riešení. Lokálna mutácia `muta` vykonáva menšie aditívne zmeny a pomáha spresňovať riešenie v okolí aktuálneho jedinca. Ich kombinácia umožňuje vyvažovať globálny prieskum a lokálne doladovanie.

Ablačný experiment

Ablačný experiment skúma prínos jednej časti algoritmu tak, že sa táto časť odstráni a ostatné podmienky zostanú nezmenené. Preto sa varianty `f-i` musia odlišovať od variantu `e` iba vypnutým operátorom. Ak by sa súčasne menili aj ďalšie parametre, nebolo by možné určiť, ktorá zmena spôsobila pozorovaný rozdiel.

Interpretácia stochastických výsledkov

Genetický algoritmus používa náhodnosť pri inicializácii a často aj pri selekcii, krížení a mutácii. Jeden beh preto nie je dostatočný na všeobecný záver. Pri interpretácii porovnávajte nielen najlepší výsledok, ale aj typický priebeh, priemer a rozptyl medzi behmi. Kvalitné nastavenie by malo dosahovať dobré výsledky opakovane, nie iba v jednom výnimočnom spustení.